M21 - dplyr

LearningSpoonsR

2019-02-11

I. Packages & Files

II. ISLR 패키지의 Carseats 불러오기

III. dplyr

I. Packages & Files

Package

- 정의
  - 응용 프로그램, 확장 프로그램, library
  - 패키지는 데이터나 함수를 제공하는 프로그램
- R의 Package
  - R을 처음에 설치하면 **base**라는 package가 인스톨 되어있음
  - **base**외의 확장 기능을 제공하는 패키지를 설치하여 사용
  - **dplyr**, **ggplot2**, **rmarkdown**등의 강력한 패키지 위주로 수업합니다.
- Package의 위상
  - R과 Python을 오픈 소스 기반 언어
  - 누구나 패키지를 만들고 공유할 수 있음
  - 많은 사람들이 많은 패키지를 만들면서 발전이 일어남
- Package의 간단한 이해

Environment (환경)	Application (응용프로그램)
윈도우	Excel
안드로이드	카카오톡
R	**dplyr**, **ggplot2**, **rmarkdown**
Python	**pandas**, **numpy**

설치

- base외의 패키지를 사용하려면 설치를 먼저 해주어야 함
- 마치 playstore에서 앱을 다운 받아 설치하는 것과 같음
- 따옴표를 넣어서 패키지의 이름을 입력

```
install.packages("package_name")
install.packages("dplyr")
```

사용 선언

- 코드에서 패키지를 사용하기 전에 패키지 사용을 선언해주어야 함
- “declare”, “import”, “load”라고 표현
- 따옴표 없이 아래처럼 입력

```
library(package_name)
library(dplyr)
```

File types

Source 파일

- 서식(폰트의 종류과 크기)이 없기에 메모장에서도 편집/저장 가능
- `.R`
  - R 문법을 따르는 명령어로 구성
- `.Rmd`
  - 3가지 부분으로 구성되어 문서 생성
    - `Yaml`: 문서의 포맷 결정하는 부분
    - `Markdown`: 워드프로세서처럼 자유롭게 작성
    - `R chunks`: R 명령어

Data 파일

- 일반 데이터 파일
  - `.csv`
    - Comma Seperated Values
    - 분리자(seperator)가 컴마(comma)로 정형화된 파일
  - `.txt`
    - 다양한 분리자로 구분된 파일
  - `.xls`, `.xlsx`
- R 데이터 파일
  - R에서 작업중인 데이터를 저장하고 불러오는 파일
  - `.Rdata`
    - 현재 메모리 상태를 저장하고 나중에 복원할 수 있음
    - 작업을 이어서 하는데에 유용
  - `.Rda`
    - 1개 함수나 변수를 저장하는 파일

데이터 파일 입출력

파일을 불러오면 data.frame 객체로 저장됨!

1. .csv

- 첫 번째 행이 제목인 경우, 첫 번째 행이 **dataset**의 column name이 됨
- **header=TRUE**가 default input (입력하지 않아도 자동으로 **header=TRUE**가 됨)
- **stringsAsFactors = FALSE**를 넣지 않으면 **data.frame**의 모든 string변수가 factor형으로 저장됨

```
dataset <- read.csv("file_name.csv", header = TRUE, stringsAsFactors = FALSE)
dataset <- read.csv("file_name.csv", stringsAsFactors = FALSE)
```

- 첫 번째 행이 제목이 아니라면 **header=FALSE**를 넣어줘야겠죠?

```
dataset <- read.csv("file_name.csv", header = FALSE, stringsAsFactors = FALSE)
```

- **dataset**을 **file_name.csv**로 저장하려면?

```
write.csv(dataset, "file_name.csv")
```

2. .txt

- csv파일과 매우 유사
- csv파일은 구분자가 comma이기에 별도의 입력이 필요하지 않았지만…
- txt파일에서는 구분자(seperator, sep)를 입력해주어야 함.
- Ex) sep="\t" (Tab), sep="." (Period), sep="\n" (Linebreak)

```
dataset <- read.table("file_name.txt", header = FALSE, sep = "\t", stringsAsFactors = FALSE
write.table(dataset, "fileName.txt") # save
```

3. .xls, .xlsx

- 불러오기는 가능
- 저장은 불가능
- col_names=FALSE는 header=FALSE에 대응
- stringsAsFactors = FALSE를 하지 않아도 string으로 저장

```
library(readxl)
dataset <- read_excel("file_name.xlsx")
dataset <- read_excel("file_name.xlsx", col_names = FALSE)
```

4. R 데이터 파일

- 특정 객체(변수 혹은 함수) 1개를 저장하고 나중에 사용

```r
save(dataset, "file_name.rda") # save
load("file_name.rda") # load
```

- 현재 메모리의 모든 객체(변수와 함수)를 저장하고 나중에 복원 가능

```r
save("file_name.Rdata") # save
load("file_name.Rdata") # load
```

경로 (path & directory)

Working directory

- R엔진이 인식하고 있는 현재 폴더
  - `getwd()`를 실행하면 확인 가능
  - `setwd("directory_you_want")`를 사용해서 변경가능
- R Studio 실행 방식에 따라서 working directory가 달라짐
  - Rstudio 아이콘을 더블클릭해서 실행 → 디폴트 설정값
  - `.R`이나 `.Rmd`파일들 더블클릭해서 실해 → 해당 소스파일이 위치한 폴더

경로 (path)

- 절대경로
  - WD와 상관없이 전체 경로로 입력
  - Ex1) `read.csv("C:/LS-DS/M21/data/file_name.csv")`
  - 컴퓨터나 폴더가 변경되면 다시 지정해줘야 함
- 상대경로
  - WD 기준으로 입력
  - Ex2) `read.csv("file_name.csv")`가 제대로 작동하려면 WD에 `file_name.csv`가 존재해야 함.
  - Ex3) WD가 `"C:/LS-DS/M21"`인 경우에 `read.csv("/data/file_name.csv")`을 입력하면 Ex1)과 같음
  - `..`을 이용하면 상위 폴더 (parent directory)로 이동
  - Ex4) WD가 `"C:/LS-DS/M22"`인 경우에 `read.csv("../M21/data/file_name.csv")`을 입력하면 Ex1)과 같음
- Tip
  - Project 단위로 폴더를 만들어서 관리
  - 소스파일은 해당 폴더에 보관
  - 같은 폴더, 혹은 데이터 파일이 여러개인 경우에 `/data/` 폴더에 데이터파일 보관하며 상대경로를 이용해서 불러오기

II. ISLR 패키지의 Carseats 불러오기

- 수백개의 오프라인 매장에서 카시트를 판매하는 업체의 매장별 판매 데이터

```
install.packages("ISLR") # install when using for the first time
```

```
library(ISLR) # load `ISLR` package
class(Carseats) # data structure
```

```
## [1] "data.frame"
```

```
head(Carseats) # the first 6 observations
```

```
##   Sales CompPrice Income Advertising Population Price ShelveLoc Age
## 1  9.50       138     73          11        276   120       Bad  42
## 2 11.22       111     48          16        260    83      Good  65
## 3 10.06       113     35          10        269    80    Medium  59
## 4  7.40       117    100           4        466    97    Medium  55
## 5  4.15       141     64           3        340   128       Bad  38
## 6 10.81       124    113          13        501    72       Bad  78
##   Education Urban  US
## 1        17   Yes Yes
## 2        10   Yes Yes
## 3        12   Yes Yes
## 4        14   Yes Yes
## 5        13   Yes  No
## 6        16    No Yes
```

```
tail(Carseats, 2) # the last 2 observations
```

```
##     Sales CompPrice Income Advertising Population Price ShelveLoc Age
## 399  5.94       100     79           7        284    95       Bad  50
## 400  9.71       134     37           0         27   120      Good  49
##     Education Urban  US
## 399        12   Yes Yes
## 400        16   Yes Yes
```

```
View(Carseats) # a pop-up windows
dim(Carseats) # dimensions
```

```
## [1] 400  11
```

```
str(Carseats) # structural view
```

```
## 'data.frame':    400 obs. of  11 variables:
##  $ Sales      : num  9.5 11.22 10.06 7.4 4.15 ...
##  $ CompPrice  : num  138 111 113 117 141 124 115 136 132 132 ...
##  $ Income     : num  73 48 35 100 64 113 105 81 110 113 ...
##  $ Advertising: num  11 16 10 4 3 13 0 15 0 0 ...
##  $ Population : num  276 260 269 466 340 501 45 425 108 131 ...
##  $ Price      : num  120 83 80 97 128 72 108 120 124 124 ...
##  $ ShelveLoc  : Factor w/ 3 levels "Bad","Good","Medium": 1 2 3 3 1 1 3 2 3 3 ...
##  $ Age        : num  42 65 59 55 38 78 71 67 76 76 ...
##  $ Education  : num  17 10 12 14 13 16 15 10 10 17 ...
##  $ Urban      : Factor w/ 2 levels "No","Yes": 2 2 2 2 2 1 2 2 1 1 ...
##  $ US         : Factor w/ 2 levels "No","Yes": 2 2 2 2 1 2 1 2 1 2 ...
```

▶ 기초 통계량

```
summary(Carseats) # summary statistics
```

```
##      Sales          CompPrice       Income        Advertising
##  Min.   : 0.000   Min.   : 77   Min.   : 21.00   Min.   : 0.000
##  1st Qu.: 5.390   1st Qu.:115   1st Qu.: 42.75   1st Qu.: 0.000
##  Median : 7.490   Median :125   Median : 69.00   Median : 5.000
##  Mean   : 7.496   Mean   :125   Mean   : 68.66   Mean   : 6.635
##  3rd Qu.: 9.320   3rd Qu.:135   3rd Qu.: 91.00   3rd Qu.:12.000
##  Max.   :16.270   Max.   :175   Max.   :120.00   Max.   :29.000
##    Population        Price        ShelveLoc        Age
##  Min.   : 10.0   Min.   : 24.0   Bad   : 96   Min.   :25.00
##  1st Qu.:139.0   1st Qu.:100.0   Good  : 85   1st Qu.:39.75
##  Median :272.0   Median :117.0   Medium:219   Median :54.50
##  Mean   :264.8   Mean   :115.8                Mean   :53.32
##  3rd Qu.:398.5   3rd Qu.:131.0                3rd Qu.:66.00
##  Max.   :509.0   Max.   :191.0                Max.   :80.00
##    Education    Urban       US
##  Min.   :10.0   No :118   No :142
##  1st Qu.:12.0   Yes:282   Yes:258
##  Median :14.0
##  Mean   :13.9
##  3rd Qu.:16.0
##  Max.   :18.0
```

- 각 변수의 data type

```
sapply(Carseats, class)
```

```
##       Sales   CompPrice      Income Advertising  Population       Price
##   "numeric"   "numeric"   "numeric"   "numeric"   "numeric"   "numeric"
##   ShelveLoc         Age   Education       Urban          US
##    "factor"   "numeric"   "numeric"    "factor"    "factor"
```

- 각 변수에 대해 중복값을 제거한 관찰값 갯수

```
sapply(Carseats, function(x) length(unique(x)))
```

```
##       Sales   CompPrice      Income Advertising  Population       Price
##         336          73          98          28         275         101
##   ShelveLoc         Age   Education       Urban          US
##           3          56           9           2           2
```

III. dplyr

Background

1. 직관적인 문법으로 빠르게 **data.frame**을 다루는 패키지
   - 가장 빠른 언어인 C를 기반으로 만듬
   - 가장 직관적인 SQL (Standard Query Language)과 유사하게 만들어져있음
   - 코드 가독성이 높음
   - **그러나 base 명령어도 같이 알아두면 장점이 있음**
     - 타인의 코드 참조
     - 파이썬, SQL등 다른 언어를 배울 때 도움이 됨
2. 제작자: Hadley Wickham, Ph.D.
   - Head Scientist, Rstudio
   - **ggplot2**, **dplyr**, **reshape2**, **stringr** 등의 본인이 작성한 패키지를 묶어서 **tidyverse**라는 패키지로 묶음
   - 통계학 박사 후 R에서 다수의 사용하기 좋은 패키지 개발
   - **R for Data Science** 저자
   - youtube.com에 keynote등 좋은 동영상 많아요!
   - 누나도 통계학 전공 교수

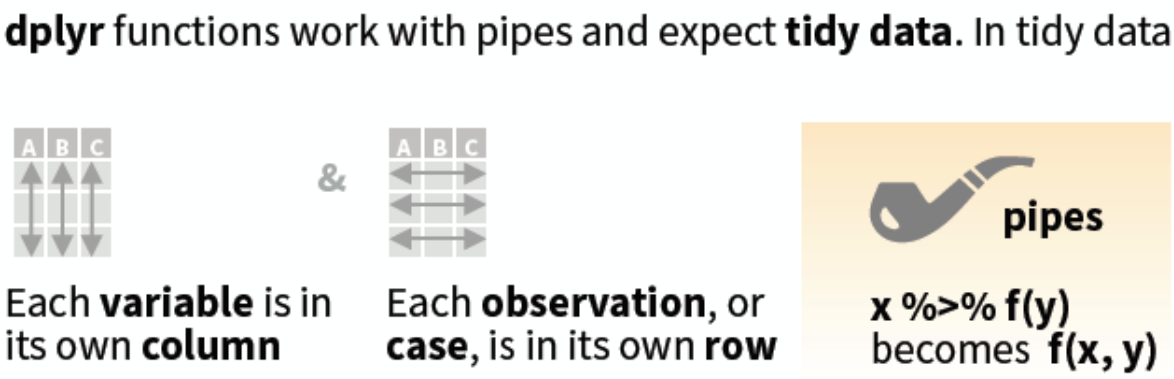

Figure 1: from `dplyr` Cheatsheet

- `dplyr`은 tidy `data.frame` 자료 구조를 가정
  1. Data Structure는 `data.frame`
  2. 각각의 row는 관찰값
  3. 각각의 column은 변수

- `pipe`는 앞에서 부터 읽게 해주어 가독성을 높임!
  - `f(x,y)`와 `x %>% f(y)`가 같음
  - Ex) 아래가 모두 같음
    - $y = (x_1 + x_2)^2 + x_3$
    - `y = add(square(x_1+x_2), x_3)`
    - `y = (x_1+x_2) %>% square() %>% add(x_3)`
    - ...

Basic Manipulations

1. **rename**
   - 변수 이름 바꾸기
   - column의 이름을 바꿈
2. **filter**
   - 관찰값 추출
   - row를 선택함
3. **select**
   - 변수 추출
   - column을 선택함
4. **arange**
   - 관찰값 정렬
   - row를 재정렬함
5. **mutate**
   - 변수 생성
   - column을 만듬
6. **group_by + summarise**
   - Categorical 변수를 이용해 집계

1. rename (이름 바꾸기)

```
library(dplyr)
# dplyr: rename `Sales` to `Revenue`
temp <- rename(Carseats, Revenue = Sales)
# base: rename `Revenue` to `Sales`
names(temp)[names(temp)=="Revenue"] <- "Sales"
```

2. filter (관찰값 추출, Row 추출)

```
# takes obs only if Income > 100
temp <- filter(Carseats, Income > 100) # dplyr
temp <- Carseats %>% filter(Income > 100) # dplyr, pipe
temp <- Carseats[Carseats$Income > 100,] # base
# takes obs only if Age between 30 and 40
temp <- filter(Carseats, Age >= 30 & Age < 40) # dplyr
temp <- Carseats %>% filter(Age >= 30 & Age < 40) # dplyr + pipe
temp <- Carseats[((Carseats$Age >= 30) & (Carseats$Age < 40)),] # base
```

3. select (변수 추출, Column 선택)

```r
# Choose the variablse Income and Population
temp <- select(Carseats, Income, Population) # dplyr
temp <- Carseats %>% select(Income, Population) # dplyr
temp <- Carseats[,c("Income", "Population")] # base
```

4. arrange (정렬)

```r
# Ascending (1-2-3)
Carseats <- arrange(Carseats, Price) # dplyr
Carseats <- Carseats %>% arrange(Price) # dplyr
Carseats <- Carseats[order(Carseats$Price),] # base
# Descending (3-2-1)
Carseats <- arrange(Carseats, desc(Price)) # dplyr
Carseats <- Carseats %>% arrange(desc(Price)) # dplyr
Carseats <- Carseats[order(Carseats$Price, decreasing = TRUE),] # base
```

5. mutate (새로운 변수 만들기)

```
# dplyr
Carseats <- mutate(Carseats,
                   AdvPerCapita = Advertising/Population,
                   RevPerCapita = Sales/Population)
# dplyr + pipe
Carseats <- Carseats %>%
  mutate(AdvPerCapita = Advertising/Population,
         RevPerCapita = Sales/Population)
# base
Carseats$AdvPerCapita <- Carseats$Advertising/Carseats$Population
Carseats$RevPerCapita <- Carseats$Sales/Carseats$Population
```

mutate with ifelse

```
# dplyr
Carseats <- mutate(Carseats, AgeClass = ifelse(Age>=60, "Silver", "non-Silver"))
# dplyr + pipe
Carseats <- Carseats %>% mutate(AgeClass = ifelse(Age>=60, "Silver", "non-Silver"))
# base
Carseats$AgeClass <- ifelse(Carseats$Age >= 60, "Silver", "non-Silver")
```

데이터셋에 대해 궁금한 점

- Carseat 회사의 주요 구매층은 아이를 낳아서 키울 나이인 30대 연령층입니다.
- 소득이 높으면서 도시의 평균 연령이 30대인 도시에 충분한 광고비를 지출하고 있나요?

```
# Successive treatments by pipe
focusCity <- Carseats %>%
  filter(Income > 100) %>% # high income
  filter(Age >= 30 & Age < 40) %>% # Take only cities with avg age = 30s
  mutate(AdvPerCapita = Advertising/Population) %>% # average per capita
  select(Sales, Income, Age, Population, Education, AdvPerCapita) %>% # select variables
  arrange(Sales) # ascending (1-2-3)
focusCity
```

```
##    Sales Income Age Population Education AdvPerCapita
## 1   5.04    114  34        298        16   0.00000000
## 2   5.32    116  39        170        16   0.00000000
## 3   6.80    117  38        337        10   0.01483680
## 4   7.49    119  35        178        13   0.03370787
## 5   7.67    117  36        400        10   0.02000000
## 6   8.55    111  36        480        16   0.04791667
## 7   8.97    107  33        144        13   0.00000000
## 8   9.03    102  35        123        16   0.10569106
## 9   9.39    118  32        445        15   0.03146067
## 10  9.58    104  37        353        17   0.06515581
## 11 10.36    105  34        428        12   0.04205607
## 12 10.59    120  30        262        10   0.05725191
## 13 12.57    108  33        203        14   0.08374384
```

6. group_by + summarise

- 도시 인구의 평균 나이가 20대, 30대, 40대 이상인 경우에 Sales에 차이가 있을까요?
  - Step 1. **AgeClass**라는 categorical 변수 생성 (by **mutate** + **ifelse**)
  - Step 2. **AgeClass**로 묶어서 (**group_by**)
  - Step 3. **mean(Sales)**를 집계 (**summarise**)
  - Step 4. 새로운 데이터셋 **ageDiff**이 만들어 짐!

```
ageDiff <- Carseats %>%
  mutate(AgeClass = # Step 1
           ifelse(Age < 30, "Twenties",
                  ifelse(Age < 40, "Thirties", "FourtyAbove"))) %>%
  group_by(AgeClass) %>% # Step 2
  summarise(avgRevenue = mean(Sales)) # Step 3
ageDiff
```

```
## # A tibble: 3 x 2
##   AgeClass    avgRevenue
##   <chr>            <dbl>
## 1 FourtyAbove       7.30
## 2 Thirties          8.26
## 3 Twenties          7.76
```

- 이번 분석의 문제점은 무엇인가요?

Discussion

- 평균 나이에 따른 평균 Revenue의 차이는 무엇을 말해주나요?
- 평균 나이가 포함하지 못하고 있는 정보는 어떤 것이 있나요?
- 어떤 데이터가 있으면 더 좋을까요?
- 그 데이터가 있으면 어떻게 하실 건가요?

Discussion

- 많은 데이터 분석은 “연속 변수”를 “이산 변수”로 생성하고,
- “이산 변수”의 group별 차이를 파악하는 접근을 사용합니다.
- ex) 연령, 소득, 기온, 성별,…
- 가능한 분석과 원리
  1. **Age**를 factor로 잡아 **Sales**의 Boxplot.
  2. **Age**를 factor로 잡아 scatterplot for **Population** & **Sales**.
  3. **3개 이상의 변수의 관계**를 생각하는 습관
  4. **공간**과 **시간**에 대한 동질성과 이질성을 생각하는 습관
  - **#generatlizationIsLearning**
  - **#universalTruth #specificTime&Place**

Discussion

dplyr vs base

	dplyr	base
문법의 특성	일상 언어	Classic 프로그래밍 언어
장점	읽고 쓰기 쉬움	타 언어와 style 유사
유사 언어	SQL	Python의 **Pandas**

SQL (Standard Query Language)

1. 대용량 데이터 베이스와 통신하는 언어
2. R에서도 **sqldf**라는 패키지를 사용해서 SQL 명령어로 작업할 수 있음 (M51)
3. R을 할 줄 아는 사람이 SQL을 배우는데 걸리는 시간 < 1 day
4. 데이터를 보는 눈을 키워 줍니다.

Data Transformation with dplyr : : CHEAT SHEET

dplyr functions work with pipes and expect **tidy data**. In tidy data:

Each **variable** is in its own **column**

&

Each **observation**, or **case**, is in its own **row**

pipes

x %>% f(y) becomes **f(x, y)**

Summarise Cases

These apply **summary functions** to columns to create a new table of summary statistics. Summary functions take vectors as input and return one value (see back).

summary function

summarise(.data, …)
Compute table of summaries.
summarise(mtcars, avg = mean(mpg))

count(x, ..., wt = NULL, sort = FALSE)
Count number of rows in each group defined by the variables in … Also **tally**().
count(iris, Species)

VARIATIONS

summarise_all() - Apply funs to every column.
summarise_at() - Apply funs to specific columns.
summarise_if() - Apply funs to all cols of one type.

Group Cases

Use **group_by()** to create a "grouped" copy of a table. dplyr functions will manipulate each "group" separately and then combine the results.

mtcars %>%
group_by(cyl) %>%
summarise(avg = mean(mpg))

group_by(.data, ..., add = FALSE)
Returns copy of table grouped by …
g_iris <- group_by(iris, Species)

ungroup(x, …)
Returns ungrouped copy of table.
ungroup(g_iris)

Manipulate Cases

EXTRACT CASES

Row functions return a subset of rows as a new table.

filter(.data, …) Extract rows that meet logical criteria. *filter(iris, Sepal.Length > 7)*

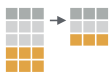

distinct(.data, ..., .keep_all = FALSE) Remove rows with duplicate values.
distinct(iris, Species)

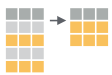

sample_frac(tbl, size = 1, replace = FALSE, weight = NULL, .env = parent.frame()) Randomly select fraction of rows.
sample_frac(iris, 0.5, replace = TRUE)

sample_n(tbl, size, replace = FALSE, weight = NULL, .env = parent.frame()) Randomly select size rows. *sample_n(iris, 10, replace = TRUE)*

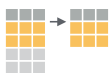

slice(.data, …) Select rows by position.
slice(iris, 10:15)

top_n(x, n, wt) Select and order top n entries (by group if grouped data). *top_n(iris, 5, Sepal.Width)*

Logical and boolean operators to use with filter()

<	<=	is.na()	%in%	|	xor()
>	>=	!is.na()	!	&	

See **?base::logic** and **?Comparison** for help.

ARRANGE CASES

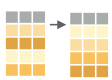

arrange(.data, …) Order rows by values of a column or columns (low to high), use with **desc()** to order from high to low.
arrange(mtcars, mpg)
arrange(mtcars, desc(mpg))

ADD CASES

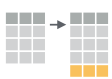

add_row(.data, ..., .before = NULL, .after = NULL) Add one or more rows to a table.
add_row(faithful, eruptions = 1, waiting = 1)

Manipulate Variables

EXTRACT VARIABLES

Column functions return a set of columns as a new vector or table.

pull(.data, var = -1) Extract column values as a vector. Choose by name or index.
pull(iris, Sepal.Length)

select(.data, …)
Extract columns as a table. Also **select_if()**.
select(iris, Sepal.Length, Species)

Use these helpers with select (),
e.g. select(iris, starts_with("Sepal"))

contains(match)	**num_range**(prefix, range)	**:**, e.g. mpg:cyl
ends_with(match)	**one_of**(…)	**-**, e.g, -Species
matches(match)	**starts_with**(match)	

MAKE NEW VARIABLES

These apply **vectorized functions** to columns. Vectorized funs take vectors as input and return vectors of the same length as output (see back).

vectorized function

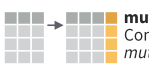

mutate(.data, …)
Compute new column(s).
mutate(mtcars, gpm = 1/mpg)

transmute(.data, …)
Compute new column(s), drop others.
transmute(mtcars, gpm = 1/mpg)

mutate_all(.tbl, .funs, …) Apply funs to every column. Use with **funs()**. Also **mutate_if()**.
mutate_all(faithful, funs(log(.), log2(.)))
mutate_if(iris, is.numeric, funs(log(.)))

mutate_at(.tbl, .cols, .funs, …) Apply funs to specific columns. Use with **funs()**, **vars()** and the helper functions for select().
mutate_at(iris, vars(-Species), funs(log(.)))

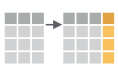

add_column(.data, ..., .before = NULL, .after = NULL) Add new column(s). Also **add_count()**, **add_tally()**. *add_column(mtcars, new = 1:32)*

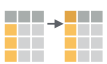

rename(.data, …) Rename columns.
rename(iris, Length = Sepal.Length)

Vector Functions

TO USE WITH MUTATE ()

mutate() and **transmute()** apply vectorized functions to columns to create new columns. Vectorized functions take vectors as input and return vectors of the same length as output.

vectorized function

OFFSETS

dplyr::**lag()** - Offset elements by 1
dplyr::**lead()** - Offset elements by -1

CUMULATIVE AGGREGATES

dplyr::**cumall()** - Cumulative all()
dplyr::**cumany()** - Cumulative any()
cummax() - Cumulative max()
dplyr::**cummean()** - Cumulative mean()
cummin() - Cumulative min()
cumprod() - Cumulative prod()
cumsum() - Cumulative sum()

RANKINGS

dplyr::**cume_dist()** - Proportion of all values <=
dplyr::**dense_rank()** - rank with ties = min, no gaps
dplyr::**min_rank()** - rank with ties = min
dplyr::**ntile()** - bins into n bins
dplyr::**percent_rank()** - min_rank scaled to [0,1]
dplyr::**row_number()** - rank with ties = "first"

MATH

+, - , *, /, ^, %/%, %% - arithmetic ops
log(), log2(), log10() - logs
<, <=, >, >=, !=, == - logical comparisons
dplyr::**between()** - x >= left & x <= right
dplyr::**near()** - safe == for floating point numbers

MISC

dplyr::**case_when()** - multi-case if_else()
dplyr::**coalesce()** - first non-NA values by element across a set of vectors
dplyr::**if_else()** - element-wise if() + else()
dplyr::**na_if()** - replace specific values with NA
pmax() - element-wise max()
pmin() - element-wise min()
dplyr::**recode()** - Vectorized switch()
dplyr::**recode_factor()** - Vectorized switch() for factors

Summary Functions

TO USE WITH SUMMARISE ()

summarise() applies summary functions to columns to create a new table. Summary functions take vectors as input and return single values as output.

summary function

COUNTS

dplyr::**n()** - number of values/rows
dplyr::**n_distinct()** - # of uniques
sum(!is.na()) - # of non-NA's

LOCATION

mean() - mean, also **mean(!is.na())**
median() - median

LOGICALS

mean() - Proportion of TRUE's
sum() - # of TRUE's

POSITION/ORDER

dplyr::**first()** - first value
dplyr::**last()** - last value
dplyr::**nth()** - value in nth location of vector

RANK

quantile() - nth quantile
min() - minimum value
max() - maximum value

SPREAD

IQR() - Inter-Quartile Range
mad() - median absolute deviation
sd() - standard deviation
var() - variance

Row Names

Tidy data does not use rownames, which store a variable outside of the columns. To work with the rownames, first move them into a column.

rownames_to_column()
Move row names into col.
a <- rownames_to_column(iris, var = "C")

column_to_rownames()
Move col in row names.
column_to_rownames(a, var = "C")

Also **has_rownames()**, **remove_rownames()**

Combine Tables

COMBINE VARIABLES

Use **bind_cols()** to paste tables beside each other as they are.

bind_cols(…) Returns tables placed side by side as a single table.
BE SURE THAT ROWS ALIGN.

Use a "**Mutating Join**" to join one table to columns from another, matching values with the rows that they correspond to. Each join retains a different combination of values from the tables.

left_join(x, y, by = NULL, copy=FALSE, suffix=c(".x",".y"),…)
Join matching values from y to x.

right_join(x, y, by = NULL, copy = FALSE, suffix=c(".x",".y"),…)
Join matching values from x to y.

inner_join(x, y, by = NULL, copy = FALSE, suffix=c(".x",".y"),…)
Join data. Retain only rows with matches.

full_join(x, y, by = NULL, copy=FALSE, suffix=c(".x",".y"),…)
Join data. Retain all values, all rows.

Use **by = c("col1", "col2")** to specify the column(s) to match on.
left_join(x, y, by = "A")

Use a named vector, **by = c("col1" = "col2")**, to match on columns with different names in each data set.
left_join(x, y, by = c("C" = "D"))

Use **suffix** to specify suffix to give to duplicate column names.
left_join(x, y, by = c("C" = "D"), suffix = c("1", "2"))

COMBINE CASES

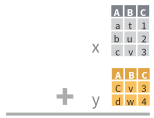

Use **bind_rows()** to paste tables below each other as they are.

bind_rows(…, .id = NULL)
Returns tables one on top of the other as a single table. Set .id to a column name to add a column of the original table names (as pictured)

intersect(x, y, …)
Rows that appear in both x and y.

setdiff(x, y, …)
Rows that appear in x but not y.

union(x, y, …)
Rows that appear in x or y. (Duplicates removed). union_all() retains duplicates.

Use **setequal()** to test whether two data sets contain the exact same rows (in any order).

EXTRACT ROWS

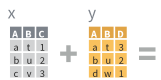

Use a "**Filtering Join**" to filter one table against the rows of another.

semi_join(x, y, by = NULL, …)
Return rows of x that have a match in y.
USEFUL TO SEE WHAT WILL BE JOINED.

anti_join(x, y, by = NULL, …)
Return rows of x that do not have a match in y.
USEFUL TO SEE WHAT WILL NOT BE JOINED.

blank

blank