#### M46-retail2

LearningSpoonsR

2019-02-10

# Background

# I. Background

- Continued from M43-retail1
  - 1. 배송 기간 분석 (Ship Date를 기반으로 배송이 가장 오래걸리는 상품은 무엇인가?)
  - 2. 마진이 가장 많이 남는 상품은 무엇인가?
  - 3. M46에서는 소비자 별 구매 기록을 분석해보자
- ▶ 맥주와 기저귀
  - ▶ Data-driven marketing의 고전적 예제
  - ▶ 맥주와 기저귀가 동시에 많이 팔린다.
  - ▶ Why? 아이를 위해 기저귀를, 나를 위해 맥주를 사는 아이 아빠들…
  - ▶ So what? 두 상품의 진열을 가깝게? 아니면 멀게해서 동선을 확보? 묶음 상품으로?
- ▶ Online Commerce?
  - ▶ "이 상품을 구매한 사람이 자주 본 물건"
  - ► "You may also like…"

# Goal

#### II. Goal

#### 목표 결과물 (Target output)


- 이 노트는 제작 과정을 최대한 재현한 노트입니다. 분석가의 생각의 흐름을 느껴보세요.
- ► From M24,
  - 0. About

  - 2. Deviation
  - 3. Ranking
  - 4. Distribution
  - 5. Composition
  - 6. Change
  - 7. Groups



## 목표 결과물 (Target output)

#### From M24. 1. Correlation,



#### 필요한 데이터셋의 구조

#### We need…

| 1     | المراسم | าเพาเ | 1234 | 241211 |
|-------|---------|-------|------|--------|
| 444   | 1000    | 580   | 31   | 3      |
| 11211 |         | 1500  | (0   | 2      |
| 1272  |         |       | 5000 | 3      |
| מאואר |         |       |      | 570    |

Figure 1: 필요한 데이터 구조

#### for···




Figure 2: 최종 output 시안

# Data Review

#### III. Data Review

- ▶ tidyverse 많이도 포함하고 있네요.
- ▶ rmarkdown 문서에 r chunk의 아웃풋 출력을 안하려면 message=FALSE하면 됩니다.

#### 이렇게 생긴 데이터이고…

```
str(dataset)
## Classes 'tbl df', 'tbl' and 'data.frame': 9994 obs. of 20 variables:
## $ Country : chr
                        "United States" "United States" "United States"
## $ Region
                        "East" "East" "South" "South" ...
                 : chr
## $ State
                 : chr
                        "Ohio" "Ohio" "Virginia" "Virginia" ...
## $ Citv
                 : chr
                        "Akron" "Akron" "Alexandria" "Alexandria" ...
## $ Postal Code : num
                        44312 44312 22304 22304 22304 ...
## $ Category
                 : chr
                        "Furniture" "Furniture" "Furniture" ...
## $ Sub-Category : chr
                        "Tables" "Furnishings" "Furnishings" "Furnishings" ...
                        "Corporate" "Consumer" "Corporate" "Home Office" ...
## $ Segment
                : chr
## $ Product Name : chr
                        "Chromcraft Rectangular Conference Tables" "Deflect-o Glass Clear
## $ Manufacturer : chr
                        "Chromcraft" "Deflect-o" "DAX" "Eldon" ...
## $ Customer Name: chr
                        "Ed Braxton" "Ted Trevino" "Andrew Gjertsen" "Shirley Daniels" .
## $ Order Date : POSIXct, format: "2014-10-21" "2011-05-18" ...
## $ Order ID
                : chr "CA-2014-147277" "CA-2011-164224" "CA-2012-104241" "US-2011-1555
## $ Ship Date
                 : POSIXct, format: "2014-10-25" "2011-05-20" ...
   $ Ship Mode
                 : chr
                        "Standard Class" "Second Class" "Standard Class" "Standard Class
##
## $ Discount
                 : num 0.4 0.2 0 0 0 0.3 0.2 0.32 0.3 0.6 ...
## $ Profit
                 : num -76 4 69 4 31 -31 3 -36 -350 -11 ...
## $ Profit Ratio : num -0.27 0.03 0.36 0.49 -0.13 0.29 -0.18 -0.14 -0.48 ...
## $ Quantity
                 : num 2 3 14 3 3 2 2 2 5 3 ...
## $ Sales
                 : num 284 149 192 12 63 ...
```

#### 이런 변수들이 있구나…

```
colnames(dataset)
## [1] "Country"
                        "Region"
                                       "State"
                                                       "City"
                        "Category"
## [5] "Postal Code"
                                       "Sub-Category"
                                                       "Segment"
## [9] "Product Name"
                        "Manufacturer"
                                       "Customer Name" "Order Date"
## [13] "Order ID"
                        "Ship Date"
                                       "Ship Mode"
                                                       "Discount"
## [17] "Profit"
                        "Profit Ratio" "Quantity"
                                                       "Sales"
관련 데이터는…
dataset %>% select('Product Name', 'Customer Name') %>% head()
## # A tibble: 6 x 2
    'Product Name'
                                                              'Customer Name'
##
## <chr>
                                                             <chr>>
## 1 Chromcraft Rectangular Conference Tables
                                                             Ed Braxton
## 2 Deflect-o Glass Clear Studded Chair Mats
                                                             Ted Trevino
## 3 DAX Wood Document Frame
                                                             Andrew Gjertsen
## 4 Eldon Image Series Black Desk Accessories
                                                             Shirley Daniels
## 5 GE General Use Halogen Bulbs, 100 Watts, 1 Bulb per Pack Shirley Daniels
## 6 Chromcraft Round Conference Tables
                                                             Anna Gayman
```

각각 컬럼의 unique한 value의 갯수는…

```
dataset %>% select(`Product Name`, `Customer Name`) %>%
    sapply(function(x) length(unique(x)))
## Product Name Customer Name
## 1850 793
```

암튼 dataset을 이용해서 Figure 1 모양의 구조를 만드는 preprocessing을 하면 되겠구나!

# Preprocessing

# Preprocessing 1: Assign IDs

Issue → Solution → Discussion → Implementation

#### Issue

- 1. Customer Name의 유일성 (uniqueness)
  - ▶ Akron에 사는 Barrack Obama → 기저귀 구매
  - ▶ L.A.에 사는 Barrack Obama → 맥주 구매
  - ▶ 그런데 둘은 다른 사람!
- 2. Product Name의 유일성과 value의 길이
  - ▶ 마찬가지로 유일성이 담보되지 않음
  - ▶ 값이 너무 김
  - ex) Chromcraft Rectangular Conference Tables

#### Discussion

- 1. ID variable(Key variable)은 데이터를 체계적으로 관리하는 도구
- 2. 없다면 유일성을 담보할 수 있는 방법으로 만들어 내야 함
- 3. 체계적으로 준비된 데이터 셋은 join및 조회가 용이함

#### Solution

- 1. Customer Name의 유일성 (uniqueness)
  - ▶ 각각 다른 CustomerID가 있어야 함
  - ▶ Postal Code(44312)와 Customer Name (Ed Braxton)으로 CustomerID를 만들자.
  - ▶ cus01321와 같은 형식으로 만들자.
- 2. Product Name의 유일성과 value의 길이
  - ▶ 각각 다른 ProductID가 있어야 함.
  - ▶ Manufacturer와 Product Name으로 ProductID를 만들자.
  - ▶ prod08231와 같은 형식으로 만들자.

#### Implementation

Step 1. unique를 사용해서 유일한 조합을 생성하여 customerTable에 저장

```
customerTable <- dataset %>% select(`Postal Code`, `Customer Name`) %>% unique()
customerTable %>% head()
## # A tibble: 6 x 2
##
    'Postal Code' 'Customer Name'
##
            <dbl> <chr>
## 1
            44312 Ed Braxton
## 2
            44312 Ted Trevino
## 3
            22304 Andrew Gjertsen
## 4
         22304 Shirley Daniels
## 5
            75002 Anna Gavman
            18103 Caroline Jumper
## 6
Step 1-1. 구매기록에 몇명의 고객이 있는지 확인
```

```
dim(customerTable)
## [1] 4910 2
```

#### Step 1-2. CustomerID 변수를 만들기

- 1. 일련 번호 생성
- 2. google "how to add leading zeros R"

```
library(stringr)
x <- 1:nrow(customerTable) %>% str_pad(5, pad = "0") # make 5-digit string by padding "0"
head(x, 3)
## [1] "00001" "00002" "00003"

3. CustomerID 변수 완성
customerTable$CustomerID <- paste0("cus", x)
```

#### Step 2. 같은 방법으로 productTable 만들기

```
productTable <- dataset %% select(Manufacturer, Product Name) %% unique()
productTable <- productTable %>%
  mutate(ProductID = paste0("prod",
                           1:nrow(productTable) %>% str pad(5, pad = "0")))
productTable %>% head(3)
## # A tibble: 3 x 3
    Manufacturer 'Product Name'
                                                          Product.TD
##
## <chr>
                 <chr>>
                                                          <chr>>
## 1 Chromcraft Chromcraft Rectangular Conference Tables prod00001
## 2 Deflect-o Deflect-o Glass Clear Studded Chair Mats prod00002
## 3 DAX
                DAX Wood Document Frame
                                                          prod00003
```

#### Step 3. 원래 데이터셋에 CustomerID와 ProductID를 부여

#### Step 3-1. CustomerID 부여

```
head(dataset[.c(5, 11:12)], 2)
## # A tibble: 2 x 3
## 'Postal Code' 'Customer Name' 'Order Date'
       <dhl> <chr>
                        <dt.t.m>
##
         44312 Ed Braxton 2014-10-21 00:00:00
## 1
## 2
          44312 Ted Trevino
                             2011-05-18 00:00:00
head(customerTable, 2)
## # A tibble: 2 x 3
## 'Postal Code' 'Customer Name' CustomerID
                         <chr>
##
         <dbl> <chr>
## 1 44312 Ed Braxton cus00001
## 2 44312 Ted Trevino cus00002
dataset <- left join(x = dataset, y = customerTable,
                  bv = c("Postal Code", "Customer Name"))
dataset[c(5, 11:12, 21)] %>% head(2)
## # A tibble: 2 x 4
## 'Postal Code' 'Customer Name' 'Order Date' CustomerID
##
          <dbl> <chr>
                         <dt.t.m>
                                                <chr>>
## 1
        44312 Ed Braxton 2014-10-21 00:00:00 cus00001
## 2
        44312 Ted Trevino 2011-05-18 00:00:00 cus00002
성공!
```

#### Step 3-2. 같은 방법으로 ProductID 부여

#### Step 4. 전처리 완료! 필요한 변수만 모아서 dataset2라고 이름 붙임!


```
dataset2 <- dataset %>%
  select(CustomerID, ProductID, `Postal Code`,
        'Customer Name', Manufacturer, 'Product Name') %>%
  arrange(CustomerID, ProductID)
dataset2[108:110.]
## # A tibble: 3 x 6
## CustomerID ProductID `Postal Code` `Customer Name` Manufacturer
## <chr> <chr>
                                <dbl> <chr>
                                                    <chr>>
## 1 cus00038 prod00047
                               60505 Barry Franzosi~ Global
## 2 cus00038 prod00543
                               60505 Barry Franzosi~ Acco
## 3 cus00038 prod00550
                               60505 Barry Franzosi~ TOPS
## # ... with 1 more variable: 'Product Name' <chr>
```

M46-retail2

M46-retail2

# Preprocessing 2

Strategy



#### Implementation - Step 1

#### Before

```
dataset2 %>%
  select(CustomerID, ProductID) %>%
  head()
## # A tibble: 6 x 2
##
    CustomerID ProductID
                <chr>>
##
     <chr>>
## 1 cus00001 prod00001
  2 cus00001
               prod00384
## 3 cus00002
               prod00002
## 4 cus00002
                prod00396
## 5 cus00003
                prod00003
## 6 cus00004
               prod00004
```

#### After

```
purchase <- dataset2 %>%
  group bv(CustomerID) %>%
  summarise(
    Purchases =
      paste(ProductID, collapse = " "))
head(purchase)
## # A tibble: 6 x 2
    CustomerID Purchases
     <chr>>
                <chr>>
## 1 cus00001
                prod00001 prod00384
## 2 cus00002
                prod00002 prod00396
## 3 cus00003
                prod00003
## 4 cus00004
                prod00004 prod00005 prod00411
## 5 cus00005
                prod00006 prod00415
## 6 cus00006
                prod00007 prod00417
```

## Implementation – Step 2

# Prepare an empty matrix, purchaseCount

#### And with purchase\$Purchase

```
purchaseCount
                                                purchase$Purchases %>% head(3) %>% t() %>% t()
uProductID <- unique(dataset2$ProductID)</pre>
                                                ##
                                                        [,1]
purchaseCount <-
                                                ## [1,] "prod00001 prod00384"
  array(0, c(length(uProductID),length(uProduct##D[2), | "prod00002 prod00396"
colnames(purchaseCount) <- uProductID</pre>
                                                ## [3.] "prod00003"
rownames(purchaseCount) <- uProductID
purchaseCount[1:4,1:3]
##
             prod00001 prod00384 prod00002
## prod00001
## prod00384
## prod00002
## prod00396
```

#### Fill purchaseCount

```
a ## [1] "2019-01-21 15:16:40 KST" b ## [1] "2019-01-21 18:16:16 KST"
```

b-a ## Time difference of 2.993472 hours

- ## Time difference of 2.993472 not
  - ► Code Review
    - ▶ 시간이 오래걸린 작업이므로 save.image(file = "M46\_middle.Rdata")로 현재 메모리 상태 저장
    - ▶ load("M46\_middle.Rdata")를 이용하면 저장된 메모리 상태 불러올 수 있음
    - ▶ 소요시간 확인을 위해서 a와 b를 기록
    - ▶ library(beepr), beep()으로 소리를 내어서 작업 완료를 알려줌 (기다리면서는 무엇을 하나요? <del>기</del>록)
  - Discussion
    - ▶ 속도를 빠르게 하려면 어떻게 해야할까요?
    - ► Hint?

# Results

#### Result 1

Step. 1. 각 ProductID별로 pair 구매 건수를 집계하고 정렬

- ▶ purchaseCount의 각 column의 합을 구하고…
- ▶ 해당 제품 구매 건수를 빼주면 pair 구매 건수가 집계됨
- ▶ 그것을 내림차순으로 정렬하면 pairCount완성

```
pairCount <- colSums(purchaseCount) - diag(purchaseCount)
pairCount <- sort(pairCount, decreasing = TRUE)
head(pairCount)</pre>
```

```
## prod00579 prod00445 prod00423 prod00116 prod00156 prod00018
## 104 90 80 48 46 43
```

Step. 2. pair 구매가 많았던 8개 ProductID만 골라서 8 by 8 표로 표현

- ▶ mat\_size를 8로 지정
- ▶ pairCount[1:mat\_size]의 names들이 productID 형식으로 표현되어 있으므로…
- ▶ names()를 이용해서 purchaseCount를 subsetting함!!

```
mat size <- 8
pair_mat <- purchaseCount[names(pairCount[1:mat_size]),</pre>
                           names(pairCount[1:mat size])]
pair mat %>% head()
             prod00579 prod00445 prod00423 prod00116 prod00156 prod00018
##
## prod00579
                    46
## prod00445
                               48
## prod00423
                                         46
## prod00116
                                                    18
## prod00156
                                                              14
## prod00018
                                                                         14
             prod00469 prod00476
##
## prod00579
## prod00445
## prod00423
## prod00116
## prod00156
## prod00018
```

Figure 1 완성!!!

```
M46-retail2
```

- ▶ pair\_mat의 index들을 productID형식에서 productName형식으로 바꾸려면?
- ▶ 먼저 productTable을 이용해서 pair\_mat의 ID를 매치시킴

```
pair mat name <-
  left join(data.frame(ProductID = colnames(pair mat)), productTable)
## Joining, by = "ProductID"
## Warning: Column `ProductID` joining factor and character vector, coercing
## into character vector
pair mat name %>% head()
    Product.TD
                    Manufacturer
## 1 prod00579
                           Other
## 2 prod00445
               Staple envelope
## 3 prod00423 Easy-staple paper
## 4 prod00116
                              ΚI
## 5 prod00156
                         Eldon
## 6 prod00018
                          Global
##
                                        Product Name
## 1
                                             Staples
## 2
                                     Staple envelope
## 3
                                   Easy-staple paper
                          KI Adjustable-Height Table
## 4
## 5
                         Eldon Wave Desk Accessories
## 6 Global Wood Trimmed Manager's Task Chair, Khaki
```

#### ▶ pair\_mat의 rownames를 교체

```
rownames(pair_mat) <- pair_mat_name[,"Product Name"] %>% substr(1,20)
pair_mat
##
                        prod00579 prod00445 prod00423 prod00116 prod00156
## Staples
                               46
## Staple envelope
                                          48
## Easy-staple paper
                                                    46
## KI Adjustable-Height
                                                              18
## Eldon Wave Desk Acce
                                                                        14
## Global Wood Trimmed
## Hot File 7-Pocket. F
## Storex Dura Pro Bind
##
                        prod00018 prod00469 prod00476
## Staples
## Staple envelope
## Easy-staple paper
## KI Adjustable-Height
## Eldon Wave Desk Acce
## Global Wood Trimmed
                               14
                                          13
## Hot File 7-Pocket, F
## Storex Dura Pro Bind
                                                    17
진짜로 Figure 1 완성!!!
```

#### Step. 3. pair 구매가 2회 이상이었던 10개 case를 random하게 출력

```
topPair N <- 10
# Replace diagonals to 0
purchaseCount offdiag <- purchaseCount
diag(purchaseCount offdiag) <- 0</pre>
# Find >=2 counts and build data.frame
top_indexes <-
  which(purchaseCount offdiag >= 2, arr.ind = TRUE) %>% data.frame()
top indexes %>% head()
##
             row col
## prod00543 106 27
## prod00394 212 33
## prod01458 41 35
## prod00270 694 39
## prod00435 35 41
## prod01466 68 64
colnames(purchaseCount_offdiag) %>% head()
## [1] "prod00001" "prod00384" "prod00002" "prod00396" "prod00003" "prod00004"
```


```
Top_N[,1] <- substr(Top_N[,1], 1, 30)
Top_N[,2] \leftarrow substr(Top_N[,2], 1, 30)
Top N %>% head(2)
                     Product Name.x
##
                                                    Product Name.y count
        Acco Hot Clips Clips to Go
                                           Flat Face Poster Frame
## 1
## 2 Wilson Jones Active Use Binder GBC Recycled VeloBinder Covers
Top_N에서 random하게 topPair_N개 행을 뽑으면 끝!
Top_N[sample(1:nrow(Top_N), topPair_N),]
##
                     Product Name.x
                                                     Product Name.y count
## 62 Avery Fluorescent Highlighter Acco Side-Punched Conventional
## 42 Peel & Stick Add-On Corner Poc
                                                  Easy-staple paper
## 31
                           Newell 34
                                                    Staple envelope
## 32
                          Xerox 1971
                                                    Staple envelope
## 53 Carina Double Wide Media Stora 1.7 Cubic Foot Compact "Cube"
                                                                        2
## 9 DMI Eclipse Executive Suite Bo
                                                          Avery 485
## 55 1.7 Cubic Foot Compact "Cube" Carina Double Wide Media Stora
## 48 Belkin Premiere Surge Master I SAFCO Optional Arm Kit for Wor
                                                                        2
## 47
                           Xerox 192 X-Rack File for Hanging Folder
                                                                        2
                   OIC Binder Clips Eldon Wave Desk Accessories
## 35
```

#### Result 2

Step. 1. 예제 코드를 이용해 Correlogram 그리기 연습

```
library(ggplot2)
library(ggcorrplot)
data(mtcars)
corr <- round(cor(mtcars), 1)
fig_sample <-
    ggcorrplot(
    corr, hc.order = TRUE, type = "lower", lab = TRUE,
    lab_size = 3, method="circle",
    colors = c("tomato2", "white", "springgreen3"),
    title="Correlogram of mtcars", ggtheme=theme_bw)</pre>
```






# Step. 2. pair\_mat를 이용해 correlogram 그리기

```
colnames(pair_mat) <- rownames(pair_mat)
fig_corr <-
   ggcorrplot(
   pair_mat, hc.order = TRUE, type = "lower", lab = TRUE,
   lab_size = 3, method="circle",
   colors = c("tomato2", "white", "springgreen3"),
   title="Correlogram of mtcars", ggtheme=theme_bw)</pre>
```





Summary

## Summary


```
save.image("M46_final.Rdata")
```

- ► Result1
  - ▶ Step. 2.
    - pair\_mat
    - ▶ pair 구매가 많았던 8개 **ProductID**만 골라서 8 by 8 표로 표현
  - Step. 3.
    - Top\_N
    - ▶ pair 구매가 2회 이상이었던 10개 case를 random하게 출력
- ► Result2
  - ► Step. 2.
    - ▶ fig\_corr
    - ▶ pair\_mat를 이용해 correlogram 그리기

# Shiny Presentation

- 1. load("M46\_final.Rdata")를 이용해서 데이터를 불러옵니다.
- 2. 위의 8과 10을 사용자의 인풋으로 받아서 다음 작업을 수행합니다.
- 3. Correlogram
  - ▶ input\$mat\_size를 seq(from = 8, to = 14, by = 2)에서 선택
  - ▶ pair\_mat 만들기 (from purchaseCount and productTable)
  - ▶ fig\_corr 만들기 (from pair\_mat)
- 4. Top\_N table
  - ▶ input\$topPair\_N를 seq(from = 10, to = 30, by = 5)에서 선택
  - ▶ Top\_N 만들기 (from purchaseCount and productTable)
- 5. flexdashboard + shiny로 다음을 포함한 대시보드를 만들어 보세요.
  - ▶ 사용자 인풋창
  - 3번 결과물
  - ▶ 4번 결과물
- 6. 결과물
  - https://learningspoonsr.shinyapps.io/M46-retail2-correl/

#### Sketch Notes



- ▶ Verumtamen oportet me bodie et cras et sequenti die ambulare.
- ▶ 오늘도 내일도 그 다음날도 계속해서 내 길을 가야 한다.