

M51-tidyr

learningSpoonsR@gmail.com



Part 0. Setup

Part I. **join**: 두 개의 데이터 프레임을 합하는 법 (a.k.a. **merge**)

Part II. From ‘untidy’ to ‘tidy’

Part 0. Setup

```
library(tidyverse) # Wickham's
library(sqldf)
source("infile-tidyr.R")
```

1. tidyverse

- ▶ Wickham이 만든 packages들을 다 모아놓은 패키지
- ▶ `ggplot2`, `dplyr`, `tidyr`, `readr`, `purrr`, `tibble`, `stringr`, `forcats`
- ▶ <https://www.tidyverse.org/packages/>

2. sqldf

- ▶ R에서 SQL 명령어를 사용할 수 있게 해주는 패키지
- ▶ SQL은 대용량의 복잡한 데이터를 다루는 데에 적합한 언어
- ▶ 이런 Cross-Language 패키지들은 새로운 환경에서의 연착륙을 도와줌

3. source("infile-tidyr.R")

- ▶ 해당 R 소스코드를 실행한 효과가 나옴
- ▶ 긴 코드를 보이지 않게 숨기게 하는데에 유용함
- ▶ 이번 노트에 사용되는 데이터프레임들을 정의하는 코드
- ▶ 아래와 같은 코드가 들어있습니다.

```
df1 <- data.frame(
  CustomerId = c(1:5),
  Product = c(rep("Toaster", 3), rep("Radio", 2)))
df2 <- data.frame(
  CustomerId = c(2, 4, 6),
  State = c(rep("Seoul", 2), rep("Busan", 1)))
```

Part I. `join`: 두 개의 데이터 프레임을 합하는 법 (a.k.a. `merge`)

0. df1과 df2를 어떻게 합해야 할까요?

df1

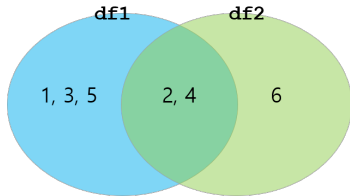
```
##   CustomerId Product
## 1          1  Toaster
## 2          2  Toaster
## 3          3  Toaster
## 4          4   Radio
## 5          5   Radio
```

df2

```
##   CustomerId State
## 1          2  Seoul
## 2          4  Seoul
## 3          6  Busan
```

- ▶ 어느쪽이 primary?
- ▶ 결측치가 생겨도 상관없음?

▶ join에는 4가지 방법이 있습니다.



1. inner
2. left
3. full (outer)
4. right

1. Inner Join

```
inner_join(df1, df2) # dplyr
merge(x = df1, y = df2, by = "CustomerId") # base
sqldf("SELECT * FROM df1 JOIN df2 USING(CustomerID)") # sqldf

## Joining, by = "CustomerId"
##   CustomerId Product State
## 1           2 Toaster Seoul
## 2           4   Radio Seoul
```

2. Left Join

```
left_join(df1, df2) # dplyr
merge(x = df1, y = df2, by = "CustomerId", all.x = TRUE) # base
sqldf("SELECT * FROM df1 LEFT JOIN df2 USING(CustomerID)") # sqldf
```

```
## Joining, by = "CustomerId"
##   CustomerId Product State
## 1           1 Toaster  <NA>
## 2           2 Toaster  Seoul
## 3           3 Toaster  <NA>
## 4           4   Radio  Seoul
## 5           5   Radio  <NA>
```


3. Outer Join (full)

```
full_join(df1, df2) # dplyr
merge(x = df1, y = df2, by = "CustomerId", all = TRUE) # base
# sqldf does not support FULL JOIN, needing three lines.
a <- sqldf("SELECT * FROM df1 LEFT JOIN df2 USING(CustomerID)")
b <- sqldf("SELECT * FROM df2 LEFT JOIN df1 USING(CustomerID)")
union(a,b) # Other set operations: intersect(a,b), setdiff(a,b), setdiff(b,a)

## Joining, by = "CustomerId"
##   CustomerId Product State
## 1           1 Toaster  <NA>
## 2           2 Toaster  Seoul
## 3           3 Toaster  <NA>
## 4           4   Radio  Seoul
## 5           5   Radio  <NA>
## 6           6   <NA>  Busan
```

4. Right Join

```
right_join(df1, df2) # dplyr
merge(x = df1, y = df2, by = "CustomerId", all.y = TRUE) # base
# sqldf does not support RIGHT JOIN, just swapping the input order.
sqldf("SELECT * FROM df2 LEFT JOIN df1 USING(CustomerID)") # sqldf
```

```
## Joining, by = "CustomerId"
##   CustomerId Product State
## 1           2 Toaster  Seoul
## 2           4   Radio  Seoul
## 3           6    <NA>  Busan
```

Summary

▶ Summary

```
inner_join(df1, df2)
left_join(df1, df2)
full_join(df1, df2)
right_join(df1, df2)
```

▶ join할때 사용할 key변수를 구체화

- ▶ `by` = argument로 key 변수를 아래처럼 지정합니다.
- ▶ `by` = 을 입력하지 않으면 같은 이름의 변수를 찾아서 key로 사용합니다.

```
inner_join(df1, df2)
inner_join(x=df1, y=df2)
inner_join(x=df1, y=df2, by = "CustomerId")
inner_join(x=df1, y=df2, by = c("CustomerId"))
inner_join(x=df1, y=df2, by = c("CustomerId"="CustomerId"))
```

- ▶ `vlookup`이나 `index-match`함수를 이용해서 엑셀 파일 합해본 경험있으세요?
- ▶ R에서는 이게 정말 끝입니다.

Discussion

- ▶ 여러분의 데이터가...
 - ▶ 각각의 관찰값에 1개 혹은 2개의 key 변수를 가지고 관리되고 있습니까?
 - ▶ → (아니라면 직관적인 처리를 위해서 만드는 것이 좋습니다.)
 - ▶ 여러 분의 key변수는 알기 쉽고, 중복되지 않고, 체계적인 규칙을 가지고 있습니까?
 - ▶ → (주민등록번호를 생각해 보세요!)

Appendix - NA의 처리

```
df3 <- full_join(df1, df2)

## Joining, by = "CustomerId"
df3$Population <- c(NA, 1000, NA, 1000, NA, 200)
df3

##   CustomerId Product State Population
## 1           1  Toaster  <NA>         NA
## 2           2  Toaster Seoul       1000
## 3           3  Toaster  <NA>         NA
## 4           4   Radio Seoul       1000
## 5           5   Radio  <NA>         NA
## 6           6   <NA> Busan        200
```

- ▶ 여러가지 이유로 위처럼 NA (결측치)가 생깁니다.
- ▶ 주로 3가지 방법으로 해결합니다.
 1. 결측치가 있는 관찰값을 제거하기
 2. 그대로 두고 함수를 적용할 때 주의해서 분석
 3. 결측치를 다른 수치로 대체하기 (평균, 0 등의 값)

1. 결측치가 있는 관찰값을 제거하기

dplyr

```
df3 %>% filter(!is.na(State))

##   CustomerId Product State Population
## 1           2 Toaster Seoul       1000
## 2           4  Radio Seoul       1000
## 3           6   <NA> Busan         200
```

base

```
is.na(df3$State)
## [1] TRUE FALSE TRUE FALSE TRUE FALSE
is.na(df3$State) %>% which()
## [1] 1 3 5
df3[!(is.na(df3$State) %>% which()),]

##   CustomerId Product State Population
## 2           2 Toaster Seoul       1000
## 4           4  Radio Seoul       1000
## 6           6   <NA> Busan         200
```

▶ 아래 명령들도 같은 결과를 만들어 냅니다.

```
df3[!is.na(df3$State),]
df3[which(!is.na(df3$State)),]
```

2. 그대로 두고 함수를 적용할 때 주의해서 분석

▶ 많은 함수들에서 `na.rm=TRUE`의 옵션 사용이 가능합니다.

```
mean(df3$Population)
```

```
## [1] NA
```

```
mean(df3$Population, na.rm = TRUE)
```

```
## [1] 733.3333
```

```
sd(df3$Population)
```

```
## [1] NA
```

```
sd(df3$Population, na.rm = TRUE)
```

```
## [1] 461.8802
```

3. 결측치를 다른 수치로 대체하기 (평균, 0등의 값)

dplyr

```
df3 %>% mutate(
  Population =
    if_else(
      is.na(Population), # Condition
      mean(Population, na.rm = TRUE), # T
      Population)) # F
```

```
##   CustomerId Product State Population
## 1           1  Toaster  <NA>    733.3333
## 2           2  Toaster Seoul  1000.0000
## 3           3  Toaster  <NA>    733.3333
## 4           4   Radio Seoul  1000.0000
## 5           5   Radio  <NA>    733.3333
## 6           6    <NA> Busan   200.0000
```

base

```
is.na(df3$Population)
## [1] TRUE FALSE TRUE FALSE TRUE FALSE
df3$Population[is.na(df3$Population)] <-
  mean(df3$Population, na.rm = TRUE)
df3
```

```
##   CustomerId Product State Population
## 1           1  Toaster  <NA>    733.3333
## 2           2  Toaster Seoul  1000.0000
## 3           3  Toaster  <NA>    733.3333
## 4           4   Radio Seoul  1000.0000
## 5           5   Radio  <NA>    733.3333
## 6           6    <NA> Busan   200.0000
```


Part II. From 'untidy' to 'tidy'

0. 단정한 데이터?

- ▶ M21 p.17
- ▶ tidy data.frame!
 1. 개체 타입은 `data.frame`
 2. 각각의 row는 관찰값을 의미
 3. 각각의 column은 변수를 의미

dplyr functions work with pipes and expect **tidy data**. In tidy data:



Each **variable** is in
its own **column**

&



Each **observation**, or
case, is in its own **row**



pipes

`x %>% f(y)`
becomes `f(x, y)`

Figure 1: from **dplyr** Cheatsheet

table1

```
## # A tibble: 6 x 4
##   country    year  cases population
##   <chr>      <int> <int>      <int>
## 1 Afghanistan 1999     745    19987071
## 2 Afghanistan 2000    2666    20595360
## 3 Brazil       1999   37737   172006362
## 4 Brazil       2000   80488   174504898
## 5 China        1999  212258  1272915272
## 6 China        2000  213766  1280428583
```

- ▶ **table1**과 같은 정보를 담고 있지만, tidy하게 되지 않은 데이터 구조가 있습니다.
- ▶ 이들을 tidy하게 **table1** 모양으로 바꿉니다.
- ▶ Excel의 **pivot_table** 기능

0. 목적

- ▶ 각 국가의 연도별 범죄 건수와 인구수입니다.
- ▶ `table2`, `table3`, `table4`로 부터 `table1`모양을 만들어야 했던 약픈 기억이 있으신가요?

▶ Before

`table4a`

```
## # A tibble: 3 x 3
##   country    `1999` `2000`
## * <chr>      <int> <int>
## 1 Afghanistan     745   2666
## 2 Brazil          37737  80488
## 3 China           212258 213766
```

`table4b`

```
## # A tibble: 3 x 3
##   country    `1999`    `2000`
## * <chr>      <int>      <int>
## 1 Afghanistan 19987071 20595360
## 2 Brazil      172006362 174504898
## 3 China       1272915272 1280428583
```

▶ After

`table1`

```
## # A tibble: 6 x 4
##   country    year cases population
##   <chr>      <int> <int>      <int>
## 1 Afghanistan 1999     745   19987071
## 2 Afghanistan 2000     2666   20595360
## 3 Brazil      1999   37737   172006362
## 4 Brazil      2000   80488   174504898
## 5 China       1999 212258 1272915272
## 6 China       2000 213766 1280428583
```

► Before

table2

```
## # A tibble: 12 x 4
##   country    year type
##   <chr>    <int> <chr>
## 1 Afghanistan 1999 cases
## 2 Afghanistan 1999 population
## 3 Afghanistan 2000 cases
## 4 Afghanistan 2000 population
## 5 Brazil      1999 cases
## 6 Brazil      1999 population
## 7 Brazil      2000 cases
## 8 Brazil      2000 population
## 9 China       1999 cases
## 10 China      1999 population
## 11 China      2000 cases
## 12 China      2000 population
```

► After

table1

```
## # A tibble: 6 x 4
##   country    year cases population
##   <chr>    <int> <int>    <int>
## 1 Afghanistan 1999    745  19987071
## 2 Afghanistan 2000   2666  20595360
## 3 Brazil      1999  37737  172006362
## 4 Brazil      2000  80488  174504898
## 5 China       1999 212258 1272915272
## 6 China       2000 213766 1280428583
```

► Before

table3

```
## # A tibble: 6 x 3
##   country      year rate
## * <chr>      <int> <chr>
## 1 Afghanistan 1999 745/19987071
## 2 Afghanistan 2000 2666/20595360
## 3 Brazil       1999 37737/172006362
## 4 Brazil       2000 80488/174504898
## 5 China        1999 212258/1272915272
## 6 China        2000 213766/1280428583
```

► After

table1

```
## # A tibble: 6 x 4
##   country      year cases population
##   <chr>      <int> <int>      <int>
## 1 Afghanistan 1999     745    19987071
## 2 Afghanistan 2000    2666    20595360
## 3 Brazil       1999   37737   172006362
## 4 Brazil       2000   80488   174504898
## 5 China        1999  212258  1272915272
## 6 China        2000  213766  1280428583
```

1. dplyr Review (mutate)

```
table1
```

```
## # A tibble: 6 x 4
##   country      year  cases population
##   <chr>      <int> <int>      <int>
## 1 Afghanistan 1999     745   19987071
## 2 Afghanistan 2000    2666   20595360
## 3 Brazil      1999   37737   172006362
## 4 Brazil      2000   80488   174504898
## 5 China       1999  212258  1272915272
## 6 China       2000  213766  1280428583
table1 %>% mutate(rate = cases / population * 100)
```

```
## # A tibble: 6 x 5
##   country      year  cases population    rate
##   <chr>      <int> <int>      <int>    <dbl>
## 1 Afghanistan 1999     745   19987071 0.00373
## 2 Afghanistan 2000    2666   20595360 0.0129
## 3 Brazil      1999   37737   172006362 0.0219
## 4 Brazil      2000   80488   174504898 0.0461
## 5 China       1999  212258  1272915272 0.0167
## 6 China       2000  213766  1280428583 0.0167
```

1. dplyr Review (group_by & summarise)

```
table1
```

```
## # A tibble: 6 x 4
##   country      year  cases population
##   <chr>      <int> <int>      <int>
## 1 Afghanistan 1999     745    19987071
## 2 Afghanistan 2000    2666    20595360
## 3 Brazil      1999   37737   172006362
## 4 Brazil      2000   80488   174504898
## 5 China       1999  212258  1272915272
## 6 China       2000  213766  1280428583
table1 %>% group_by(year) %>% summarise(n = sum(cases))
table1 %>% count(year, wt = cases) # same as above
```

```
## # A tibble: 2 x 2
##   year      n
##   <int> <int>
## 1 1999 250740
## 2 2000 296920
```

2. gather from table4a & table4b

table4a

```
## # A tibble: 3 x 3
##   country   `1999` `2000`
## * <chr>     <int> <int>
## 1 Afghanistan     745   2666
## 2 Brazil          37737  80488
## 3 China           212258 213766
```

```
tidy4a <- table4a %>%
  gather(colnames(table4a)[-1],
         key = "year",
         value = "cases")
```

tidy4a

```
## # A tibble: 6 x 3
##   country   year cases
##   <chr>    <chr> <int>
## 1 Afghanistan 1999     745
## 2 Brazil      1999   37737
## 3 China       1999  212258
## 4 Afghanistan 2000     2666
## 5 Brazil      2000   80488
## 6 China       2000  213766
```

table4b

```
## # A tibble: 3 x 3
##   country   `1999` `2000`
## * <chr>     <int> <int>
## 1 Afghanistan 19987071 20595360
## 2 Brazil      172006362 174504898
## 3 China       1272915272 1280428583
```

```
tidy4b <- table4b %>%
  gather(colnames(table4b)[-1],
         key = "year",
         value = "population")
```

tidy4b

```
## # A tibble: 6 x 3
##   country   year population
##   <chr>    <chr>    <int>
## 1 Afghanistan 1999   19987071
## 2 Brazil      1999  172006362
## 3 China       1999  1272915272
## 4 Afghanistan 2000   20595360
## 5 Brazil      2000  174504898
## 6 China       2000  1280428583
```

- ▶ `gather()` 함수로 tidy 해줍니다.
- ▶ 이제 tidy4a와 tidy4b로 어떻게 하면 table1이 만들어 질까요??


```
inner_join(tidy4a, tidy4b)
inner_join(tidy4a, tidy4b, by = c("country", "year"))
inner_join(tidy4a, tidy4b, by = c("country"="country", "year"="year"))

## Joining, by = c("country", "year")
## # A tibble: 6 x 4
##   country    year  cases population
##   <chr>    <chr> <int>      <int>
## 1 Afghanistan 1999     745    19987071
## 2 Brazil      1999    37737   172006362
## 3 China       1999   212258  1272915272
## 4 Afghanistan 2000     2666    20595360
## 5 Brazil      2000    80488   174504898
## 6 China       2000   213766  1280428583
```

3. spread from table2

```
table2
```

```
## # A tibble: 12 x 4
##   country      year type      count
##   <chr>      <int> <chr>    <int>
## 1 Afghanistan 1999 cases      745
## 2 Afghanistan 1999 population 19987071
## 3 Afghanistan 2000 cases      2666
## 4 Afghanistan 2000 population 20595360
## 5 Brazil      1999 cases      37737
## 6 Brazil      1999 population 172006362
## 7 Brazil      2000 cases      80488
## 8 Brazil      2000 population 174504898
## 9 China       1999 cases      212258
## 10 China      1999 population 1272915272
## 11 China      2000 cases      213766
## 12 China      2000 population 1280428583
table2 %>% spread(key = "type", value = "count")
```

```
## # A tibble: 6 x 4
##   country      year cases population
##   <chr>      <int> <int>    <int>
## 1 Afghanistan 1999     745  19987071
## 2 Afghanistan 2000    2666  20595360
## 3 Brazil      1999   37737  172006362
## 4 Brazil      2000   80488  174504898
## 5 China       1999 212258 1272915272
## 6 China       2000 213766 1280428583
```

4. separate from table3

table3

```
## # A tibble: 6 x 3
##   country      year rate
## * <chr>      <int> <chr>
## 1 Afghanistan 1999 745/19987071
## 2 Afghanistan 2000 2666/20595360
## 3 Brazil      1999 37737/172006362
## 4 Brazil      2000 80488/174504898
## 5 China       1999 212258/1272915272
## 6 China       2000 213766/1280428583
table3 %>% separate(rate, into = c("cases", "population"), sep = "/")
```

```
## # A tibble: 6 x 4
##   country      year cases population
##   <chr>      <int> <chr>   <chr>
## 1 Afghanistan 1999 745     19987071
## 2 Afghanistan 2000 2666    20595360
## 3 Brazil      1999 37737   172006362
## 4 Brazil      2000 80488   174504898
## 5 China       1999 212258  1272915272
## 6 China       2000 213766  1280428583
```

참고: Classical method (stringr)

```
table3$cases <-
  sapply(strsplit(table3$rate, split = "/"), function(x) x[1])
table3$popul <-
  sapply(strsplit(table3$rate, split = "/"), function(x) x[2])
```

Summary

- ▶ M51이 끝나면 무엇을 꼭 기억해야 할까요?
 - ▶ **join**에는 4가지 종류가 있다.
 - ▶ 강의노트를 잘 보관하고 수업을 기억하면 언젠가는 노가다 위기를 타개해 줄 것이다.
 - ▶ Github에 'Star'를 한다.

'I always like to hire a lazy person to do a difficult job, because a lazy person will find an easy way to do it.'

– Bill Gates